

演講題目：如何打造台版 Edge Impulse TinyML 開發平台

講師：許哲豪 日期：2026/03/31

一、Edge AI 與 TinyML 核心概念與趨勢

- Edge AI 定義：
 - 廣義：不上網就能完成所有 AI 推論
 - 狹義：指的是在「電池供電」的極低功耗獨立裝置上，完成所有 AI 推論（即 TinyML）。
- 技術演進：AI 正從感知（影像/語音）走向生成式與代理型（Agentic AI）。硬體算力需求呈階梯式上升，從 MOPS 級別（喚醒詞、感測）一路延伸到 100+ TOPS 級別（多模態、即時翻譯）。
- 硬體挑戰：底層依賴矩陣運算，晶片加速從 CPU、GPU、DSP 演進至專用 NPU 與 ASIC，但仍面臨算力、記憶體、能耗與通訊四大「硬體牆」。

二、台灣 AI 晶片與開發板生態系

台灣具備從單板微電腦 (SBC) 到微控制器 (MCU) 的堅強硬體實力：

- SBC 開發板：涵蓋聯發科 (Genio)、耐能 (KLM730A)、凌陽、聯詠、華碩 (Tinker Board) 及晶心 (RISC-V) 等方案。
- MCU + NPU 方案：針對 TinyML，有奇景光電 (WE2 超低功耗視覺)、新唐 (M55M1 + Ethos-U55 NPU)、瑞昱 (RTL8735B) 及阿比特等，已具備極高的硬體性價比與推論能力。

三、Edge Impulse 平台

Edge Impulse 被視為 TinyML 的開發平台黃金標準，其核心價值在於提供「端到端 (End-to-End)」的極致流暢體驗：

1. 資料擷取 (Data Acquisition)：支援從手機、開發板直送或多格式檔案上傳，內建自動標註與時序分割。
2. 模型設計與訓練 (Impulse Design)：提供預處理（如頻譜分析）與機器學習/神經網路分類模組，可自訂超參數。
3. 自動優化 (EON Tuner)：自動搜尋在 Flash、SRAM、精度或延遲間取得最佳平衡的模型架構。
4. 極致部署 (EON Compiler)：獨家編譯技術能在維持精度的前提下，將模型量化（如 int8）並大幅壓縮 RAM 與 ROM 的消耗，轉換為 C++ 或 MCU 專屬函式庫。

四、願景與挑戰：如何打造「台版」開發平台

- 自建平台的技術挑戰：
 1. 模型轉換：需解決不同硬體 NPU 的算子相容性與專屬轉譯工具開發。
 2. 模型壓縮：需高效的量化、剪枝與蒸餾技術。
 3. 架構搜尋 (NAS)：難以自動生成最佳模型結構。
 4. 訓練加速：配合高速 GPU 或使用遷移學習。